

Аналитический отчёт

Введение	2
Анализ представленных данных (EDA)	4
Методология: предобработка, модели, метрики	7
Результаты регрессионных моделей	10
Результаты оптимизации регрессионных моделей	15
Результаты моделей классификации	18
Результаты оптимизации моделей классификации	21
Анализ важности признаков	24
SHAP Analysis	27
Сравнение моделей	29
Итоговый вывод	30

Введение

В процессе разработки новых лекарственных препаратов ключевой задачей является поиск соединений, которые обладают высокой эффективностью против патогена и при этом минимально токсичны для организма человека. Для количественной оценки этих свойств используются три основных фармакологических показателя: **IC50**, **CC50** и **SI**.

IC50 (полумаксимальная ингибирующая концентрация) отражает противовирусную активность соединения — чем ниже значение, тем эффективнее препарат.

CC50 (полумаксимальная цитотоксическая концентрация) характеризует токсичность для здоровых клеток — высокие значения говорят о безопасности.

SI (индекс селективности) представляет собой отношение $CC50$ к $IC50$ и показывает терапевтическое окно препарата: чем выше SI , тем лучше соотношение пользы и вреда.

В рамках данной работы представлены конфиденциальные данные о 1001 химическом соединении, содержащие 214 молекулярных дескрипторов и значения трёх целевых показателей: $IC50$, $CC50$ и SI .

Цель проекта - построить прогнозные модели машинного обучения, позволяющие по молекулярным характеристикам соединения предсказывать его фармакологическую активность.

Решаются следующие задачи:

1. **Регрессия** — предсказание численных значений $IC50$, $CC50$ и SI .
2. **Классификация** — определение, превышает ли значение каждого показателя заданный порог (медианное значение выборки для $IC50$, $CC50$, SI , а также порог $SI > 8$).

В работе тестируются различные алгоритмы машинного обучения: линейные модели, деревья решений, ансамблевые методы (Random Forest, Gradient Boosting) и XGBoost. Для каждой задачи выполняется оценка baseline-производительности, оптимизация гиперпараметров и анализ важности признаков. На основе полученных результатов выбираются

наиболее эффективные модели, которые могут быть использованы для скрининга новых соединений.

Анализ представленных данных (EDA)

1. Структура данных

Датасет содержит 1001 запись и 214 числовых признаков, представляющих собой молекулярные дескрипторы химических соединений.

Целевые переменные:

- IC50, mM - концентрация полумаксимального ингибирования (противовирусная активность)
- CC50, mM - концентрация полумаксимальной цитотоксичности
- SI - индекс селективности (отношение CC50 к IC50)

2. Анализ пропусков

Выявлено 12 столбцов с пропущенными значениями. Детальный анализ показал, что все пропуски сконцентрированы в одних и тех же 3 строках, что составляет менее 0.3% от общего объема данных. Строки были удалены как нерепрезентативные.

3. Анализ целевых переменных

Описательные статистики

	IC50, mM	CC50, mM	SI
count	1001.000000	1001.000000	1001.000000
mean	222.805156	589.110728	72.508823
std	402.169734	642.867508	684.482739
min	0.003517	0.700808	0.011489
25%	12.515396	99.999036	1.433333

50%	46.585183	411.039342	3.846154
75%	224.975928	894.089176	16.566667
max	4128.529377	4538.976189	15620.600000

Ключевые наблюдения:

- Все три переменные имеют правосторонний скос, наиболее выраженный у SI (skewness = 18.01)
- Среднее значение значительно превышает медиану, что указывает на влияние выбросов
- Наибольшая вариативность ($CV = 9.44$) наблюдается у индекса селективности


Анализ выбросов

Проведен IQR-анализ для оценки количества выбросов:


Переменная	Выбросы ($1.5 \times IQR$)	Выбросы ($3.0 \times IQR$)
IC50	14.7%	8.9%
CC50	3.9%	1.1%
SI	12.5%	8.7%

Выбросы **не удаляются**, так как:

- Представляют собой реальные химические соединения с экстремальными свойствами
- В задачах поиска лекарственных средств именно такие соединения представляют наибольший интерес
- Для работы с выбросами будет применена логарифмическая трансформация



Анализ выбросов целевых переменных



4. Ключевые выводы EDA:

1. Данные требуют логарифмической трансформации для нормализации распределений
2. Выбросы являются ценными объектами и должны быть сохранены
3. Обнаружена значительная мультиколлинеарность, требующая сокращения признакового пространства
4. Датасет очищен и готов к построению прогнозных моделей машинного обучения

Методология: предобработка, модели, метрики

1. Предобработка данных

Логарифмическая трансформация

Для приведения распределений к нормальному виду и снижения влияния выбросов выполнена логарифмическая трансформация целевых переменных:

- $pIC50 = -\log_{10}(IC50 / 1000)$ — стандартный подход
- $pCC50 = -\log_{10}(CC50 / 1000)$ — аналогично IC50
- $\log_SI = \log_{10}(SI)$ — для нормализации распределения

Удаление неинформативных признаков

Удален столбец-идентификатор Unnamed: 0, не несущий смысловой нагрузки.

Корреляционный анализ и устранение мультиколлинеарности

Мультиколлинеарность: обнаружено 154 пары признаков с коэффициентом корреляции > 0.9 , что характерно для молекулярных дескрипторов. Высокая корреляция между признаками может приводить к нестабильности моделей и переобучению.

Из каждой пары признаков с $|r| > 0.95$ удален один. В результате:

- Удалено 45 признаков
- Общее количество признаков сокращено с 210 до 165

Бинарные метки для классификации:

- IC50_binary, CC50_binary, SI_binary (по медиане)
- SI_8_binary (порог > 8)

Масштабирование: StandardScaler для всех признаков.

Разделение данных: 80% train / 20% test, random_state=42.

2. Модели

Регрессия (3 задачи): IC50, CC50, SI

Модель	Тип
LinearRegression	Линейная
DecisionTreeRegressor	Дерево
RandomForestRegressor	Ансамбль
GradientBoostingRegressor	Ансамбль
XGBRegressor	Ансамбль

Классификация (4 задачи): IC50 > медианы, CC50 > медианы, SI > медианы, SI > 8

Модель	Тип
LogisticRegression	Линейная
DecisionTreeClassifier	Дерево
RandomForestClassifier	Ансамбль

GradientBoostingClassifier	Ансамбль
XGBClassifier	Ансамбль

3. Метрики

Задача	Основная метрика	Дополнительные
Регрессия	R^2	RMSE, MAE
Классификация	F1	Accuracy, Precision, Recall, AUC-ROC

4. Процедура обучения

1. Baseline — обучение всех моделей с параметрами по умолчанию
2. Оптимизация — RandomizedSearchCV (20 итераций, 5-fold CV) для топ-2 моделей
3. Выбор лучшей — модель с максимальной метрикой на тесте

5. Интерпретация

- Feature Importance — встроенная оценка важности признаков для ансамблевых моделей
- SHAP — унифицированный анализ вклада каждого признака в предсказание

Результаты регрессионных моделей

Анализ производительности моделей

В рамках baseline-экспериментов были обучены и оценены 5 моделей машинного обучения для прогнозирования трёх целевых переменных: pIC50 (ингибирующая активность), pCC50 (цитотоксичность) и log_SI (селективность). Оценка качества проводилась на тестовой выборке (20% данных) с использованием метрик RMSE, MAE и R^2 .

1. Прогнозирование pIC50 (ингибирующая активность)

Модель	RMSE	MAE	R^2
LinearRegression	1195.0314	85.1499	-1,388,225
DecisionTree	0.8823	0.6308	0.2433
RandomForest	0.7096	0.5430	0.5106
GradientBoosting	0.7019	0.5565	0.5211
XGBoost	0.7376	0.5430	0.4711

Ключевые наблюдения:

- Лучший результат показал GradientBoosting с $R^2 = 0.5211$, что объясняет чуть более 52% дисперсии целевой переменной
- RandomForest показал сопоставимый результат ($R^2 = 0.5106$) с наименьшей MAE (0.5430)
- Линейная регрессия продемонстрировала катастрофическую производительность (отрицательный R^2), что указывает на

нелинейный характер зависимости между дескрипторами и активностью

- DecisionTree значительно уступает ансамблевым методам из-за склонности к переобучению

2. Прогнозирование pCC50 (цитотоксичность)

Модель	RMSE	MAE	R ²
LinearRegression	584.0117	41.7547	-690,025
DecisionTree	0.6994	0.4421	0.0105
RandomForest	0.5529	0.3751	0.3816
GradientBoosting	0.5647	0.3917	0.3549
XGBoost	0.5827	0.3847	0.3130

Ключевые наблюдения:

- Лучший результат показал RandomForest с $R^2 = 0.3816$, что значительно ниже, чем для pIC50
- Прогнозирование цитотоксичности оказалось более сложной задачей — все модели показывают $R^2 < 0.4$
- LinearRegression снова даёт отрицательный R^2 , подтверждая нелинейность данных
- DecisionTree практически не объясняет дисперсию ($R^2 = 0.0105$), что говорит о слабой обобщающей способности

3. Прогнозирование log_SI (селективность)

Модель	RMSE	MAE	R ²
LinearRegression	611.0203	43.7862	-540,849
DecisionTree	0.8254	0.6015	0.0130
RandomForest	0.6923	0.5078	0.3057
GradientBoosting	0.7107	0.5232	0.2682
XGBoost	0.7017	0.5000	0.2867

Ключевые наблюдения:

- Лучший результат показал RandomForest с $R^2 = 0.3057$, что является самым низким среди трёх таргетов
- Прогнозирование селективности (отношения CC50/IC50) оказалось наиболее сложной задачей, что объясняется комбинированной природой этого показателя
- XGBoost показывает второй результат ($R^2 = 0.2867$) с наименьшей MAE (0.5000) среди всех моделей
- Ансамблевые методы значительно превосходят базовые модели

Сводная таблица R² для всех моделей

Модель	IC50	CC50	SI
LinearRegression	-1,388,225	-690,025	-540,849

DecisionTree	0.2433	0.0105	0.0130
RandomForest	0.5106	0.3816	0.3057
GradientBoosting	0.5211	0.3549	0.2682
XGBoost	0.4711	0.3130	0.2867

Общие выводы

1. Нелинейность данных: Линейная регрессия показывает крайне низкие результаты (отрицательный R^2) для всех трёх таргетов, что однозначно указывает на нелинейный характер связей между дескрипторами и биологической активностью.
2. Иерархия сложности задач (по убыванию предсказуемости):
 - pIC50 (R^2 до 0.52) — наиболее предсказуемая величина
 - pCC50 (R^2 до 0.38) — умеренно сложная задача
 - log_SI (R^2 до 0.31) — наиболее сложная задача
3. Лидеры среди моделей:
 - GradientBoosting и RandomForest показывают лучшие результаты для pIC50
 - RandomForest стабильно лучший для pCC50 и log_SI
 - XGBoost показывает конкурентоспособные результаты, особенно для log_SI
4. Рекомендации для оптимизации:
 - Для pIC50: GradientBoosting ($R^2 = 0.5211$) и RandomForest ($R^2 = 0.5106$)
 - Для pCC50: RandomForest ($R^2 = 0.3816$) и GradientBoosting ($R^2 = 0.3549$)
 - Для log_SI: RandomForest ($R^2 = 0.3057$) и XGBoost ($R^2 = 0.2867$)

Полученные baseline-результаты будут использованы как отправная точка для дальнейшей оптимизации гиперпараметров и разработки более сложных моделей.

Результаты оптимизации регрессионных моделей

1. Процесс оптимизации

Для каждого таргета проведена оптимизация гиперпараметров двух лучших моделей с помощью RandomizedSearchCV (20 итераций, 5-кратная кросс-валидация).

2. Результаты по таргетам

pIC50 (ингибирующая активность)

Модель	Baseline R ²	Optimized R ²	Изменение
RandomForest	0.5106	0.4934	-0.0171
GradientBoosting	0.5211	0.4826	-0.0385

pCC50 (цитотоксичность)

Модель	Baseline R ²	Optimized R ²	Изменение
RandomForest	0.3816	0.3777	-0.0039
GradientBoosting	0.3549	0.3612	+0.0064

log_SI (селективность)

Модель	Baseline R ²	Optimized R ²	Изменение
--------	-------------------------	--------------------------	-----------

XGBoost	0.2867	0.3000	+0.0133
RandomForest	0.3057	0.2907	-0.0150

3. Итоговые лучшие модели

Таргет	Модель	R ²	RMSE	MAE	Тип
IC50	GradientBoosting	0.5211	0.7019	0.5565	Baseline
CC50	RandomForest	0.3777	0.5546	0.3789	Tuned
SI	XGBoost	0.3000	0.6951	0.5162	Tuned

Для IC50 baseline модель (GradientBoosting) показала лучшее качество, чем оптимизированная (R² 0.5211 vs 0.4826). Поэтому выбрана baseline версия.

4. Ключевые выводы

Оптимизация гиперпараметров не дала значимого улучшения — изменения в пределах статистического шума (± 0.01 - 0.02 R²). Это указывает, что потенциал роста лежит не в настройке параметров, а в других направлениях.

Рекомендации:

1. Отбор признаков и создание новых дескрипторов
2. Использование LightGBM/CatBoost и ансамблей (Stacking/Voting)
3. Увеличение итераций RandomizedSearchCV до 100+

Итоговые модели (готовы к использованию):

- `best\_IC50\_regressor.pkl` — RandomForest ($R^2 = 0.5211$)
- `best\_CC50\_regressor.pkl` — RandomForest ($R^2 = 0.378$)
- `best\_SI\_regressor.pkl` — XGBoost ($R^2 = 0.300$)

Модели достигли предела для текущих данных и признаков. Дальнейший прогресс требует работы с данными и архитектурой, а не перебора гиперпараметров.

Результаты моделей классификации

1. Анализ baseline результатов

1.1. Задача: IC50 > медианы (прогнозирование высокой активности)

Модель	Accuracy	Precision	Recall	F1	AUC
LogisticRegression	0.685	0.695	0.685	0.684	0.752
DecisionTree	0.680	0.680	0.680	0.680	0.717
RandomForest	0.710	0.710	0.710	0.710	0.787
GradientBoosting	0.725	0.726	0.725	0.725	0.767
XGBoost	0.700	0.700	0.700	0.700	0.772

Вывод: Лучший результат показывает GradientBoosting (F1 = 0.725). AUC $\approx$ 0.77 указывает на хорошую различительную способность.

1.2. Задача: CC50 > медианы (прогнозирование низкой цитотоксичности)

Модель	Accuracy	Precision	Recall	F1	AUC
LogisticRegression	0.735	0.735	0.735	0.735	0.839
DecisionTree	0.705	0.719	0.705	0.704	0.735
RandomForest	0.780	0.786	0.780	0.780	0.858
GradientBoosting	0.780	0.781	0.780	0.780	0.848
XGBoost	0.785	0.790	0.785	0.785	0.868

Вывод: Лучший результат показывает XGBoost (F1 = 0.785). Это самая успешная задача с AUC $\approx$ 0.87.

1.3. Задача: SI > медианы (прогнозирование высокой селективности)

Модель	Accuracy	Precision	Recall	F1	AUC
--------	----------	-----------	--------	----	-----

LogisticRegression	0.615	0.616	0.615	0.615	0.664
DecisionTree	0.660	0.660	0.660	0.660	0.662
RandomForest	0.670	0.670	0.670	0.670	0.716
GradientBoosting	0.645	0.645	0.645	0.645	0.704
XGBoost	0.640	0.640	0.640	0.640	0.699

Вывод: Лучший результат показывает RandomForest (F1 = 0.670). Задача значительно сложнее предыдущих (AUC $\approx$ 0.72).

1.4. Задача: SI > 8 (прогнозирование селективности выше порога)

Модель	Accuracy	Precision	Recall	F1	AUC
LogisticRegression	0.685	0.677	0.685	0.677	0.695
DecisionTree	0.685	0.683	0.685	0.684	0.683
RandomForest	0.710	0.704	0.710	0.697	0.748
GradientBoosting	0.730	0.725	0.730	0.724	0.746
XGBoost	0.730	0.725	0.730	0.724	0.764

Вывод: GradientBoosting и XGBoost показывают одинаковый F1 = 0.724. AUC $\approx$ 0.75.

2. Сводная таблица F1 для всех моделей

Модель	IC50 > медианы	CC50 > медианы	SI > медианы	SI > 8
LogisticRegression	0.684	0.735	0.615	0.677
DecisionTree	0.680	0.704	0.660	0.684
RandomForest	0.710	0.780	0.670	0.697

GradientBoosting	0.725	0.780	0.645	0.724
XGBoost	0.700	0.785	0.640	0.724

3. Топ-2 модели для оптимизации

Задача	1-е место (F1)	2-е место (F1)
IC50 > медианы	GradientBoosting (0.725)	RandomForest (0.710)
CC50 > медианы	XGBoost (0.785)	GradientBoosting (0.780)
SI > медианы	RandomForest (0.670)	DecisionTree (0.660)
SI > 8	GradientBoosting (0.724)	XGBoost (0.724)

Полученные baseline-результаты будут использованы как отправная точка для дальнейшей оптимизации гиперпараметров и разработки более сложных моделей.

Результаты оптимизации моделей классификации

1. Процесс оптимизации

Для каждой из 4 задач классификации проведена оптимизация гиперпараметров двух лучших моделей (по F1-мере) с помощью RandomizedSearchCV (20 итераций, 5-кратная кросс-валидация). Оптимизация выполнялась по метрике F1.

2. Результаты по задачам

IC50 > медианы (прогнозирование высокой активности)

Модель	Baseline F1	Optimized F1	Изменение
GradientBoosting	0.7251	0.6820	-0.0431
RandomForest	0.7101	0.6866	-0.0235

CC50 > медианы (прогнозирование низкой цитотоксичности)

Модель	Baseline F1	Optimized F1	Изменение
XGBoost	0.7852	0.8020	+0.0168
GradientBoosting	0.7802	0.7778	-0.0024

SI > медианы (прогнозирование высокой селективности)

Модель	Baseline F1	Optimized F1	Изменение
RandomForest	0.6700	0.6564	-0.0136
DecisionTree	0.6599	0.6400	-0.0199

SI > 8 (прогнозирование селективности выше порога)

Модель	Baseline F1	Optimized F1	Изменение
--------	-------------	--------------	-----------

GradientBoosting	0.7235	0.5649	-0.1586
XGBoost	0.7235	0.5926	-0.1309

3. Итоговые лучшие модели

Задача	Модель	F1	Accuracy	Precision	Recall	Тип
IC50 > медианы	GradientBoosting	0.7251	0.725	0.726	0.725	Baseline
CC50 > медианы	XGBoost	0.8020	0.800	0.853	0.757	Tuned
SI > медианы	RandomForest	0.6700	0.670	0.670	0.670	Baseline
SI > 8	GradientBoosting	0.7235	0.730	0.725	0.730	Baseline

Для 3 из 4 задач классификации baseline модели оказались лучше оптимизированных. Только CC50 > медианы показал улучшение после тюнинга.

4. Ключевые выводы

Улучшение только для одной задачи:

- Единственное значимое улучшение — CC50 > медианы (XGBoost, F1 = 0.8020, +0.0168)
- Остальные задачи показали ухудшение или остались на уровне baseline

Самая проблемная задача:

- SI > 8 — сильное ухудшение (F1 упал с 0.7235 до 0.5926, -0.13)
- Вероятная причина: переобучение на кросс-валидации

Стабильность RandomForest:

- RandomForest стабильно показывает хорошие результаты для большинства задач
- Особенно для $SI > \text{медианы}$ ($F1 = 0.670$) и $IC50$ ($F1 = 0.710$)

5. Для улучшения моделей:

1. Увеличить число итераций RandomizedSearchCV до 100+
2. Добавить сетку параметров для DecisionTree
3. Использовать GridSearchCV для тонкой настройки
4. Попробовать другие модели (LightGBM, CatBoost)

Анализ важности признаков

1. Методология

Для оценки важности признаков использовались:


- Feature importance из Random Forest
- SHAP значения (средние абсолютные значения)









Анализ проводился для всех 7 моделей (3 регрессионных + 4 классификационных).

2. Топ-5 признаков


	1-й признак	2-й признак	3-й признак
pIC50	VSA_EState8	BalabanJ	VSA_EState4
pCC50	NHOHCount	PEOE_VSA7	BCUT2D_MWLOW
log_SI	RingCount	fr_Imine	NumSaturatedHeterocycles
IC50_binary	BCUT2D_MRL OW	SlogP_VSA5	VSA_EState8
CC50_binary	NHOHCount	fr_amide	BCUT2D_MWLOW
SI_binary	VSA_EState4	MaxAbsEStateIndex	BCUT2D_MRLOW

SI_8_binary	fr_Imine	fr_Al_OH	NHOHCount
-------------	----------	----------	-----------






SHAP Analysis



Для pIC50 (активность):

- VSA_EState8 — высокие значения увеличивают активность
- BalabanJ — сложные разветвленные структуры снижают активность
- NHOHCount — водородные связи улучшают активность



Для pCC50 (токсичность):

- NHOHCount — больше OH-групп = выше токсичность (ниже pCC50)
- PEOE_VSA7 — полярные поверхности влияют на цитотоксичность

Сравнение моделей

Итоговая таблица лучших моделей

Задача	Лучшая модель	Результат
IC50 (регр.)	GradientBoosting (baseline)	$R^2 = 0.521$
CC50 (регр.)	RandomForest (tuned)	$R^2 = 0.378$
SI (регр.)	XGBoost (tuned)	$R^2 = 0.300$
IC50 (класс.)	GradientBoosting (baseline)	$F1 = 0.725$
CC50 (класс.)	XGBoost (tuned)	$F1 = 0.802$
SI (класс.)	RandomForest (baseline)	$F1 = 0.670$
SI > 8	GradientBoosting (baseline)	$F1 = 0.724$

Оптимизация дала улучшение только для двух задач: SI (регрессия, +0.013) и CC50 (классификация, +0.017). В остальных случаях baseline модели показали лучшее качество.

Лучшие модели для использования:

- **IC50:** GradientBoosting (baseline, $R^2 = 0.521$ / $F1 = 0.725$)
- **CC50:** XGBoost (tuned, $R^2 = 0.378$ / $F1 = 0.802$)
- **SI:** XGBoost (tuned, $R^2 = 0.300$) / RandomForest (baseline, $F1 = 0.670$)

Итоговый вывод

В ходе выполнения работы были построены и протестированы прогнозные модели машинного обучения для оценки фармакологической активности химических соединений. Основная цель проекта заключалась в предсказании трех ключевых показателей: ингибирующей активности (IC50), цитотоксичности (CC50) и индекса селективности (SI) как в регрессионной, так и в классификационной постановках.

Ключевые результаты и выводы:

- Преобладание нелинейных методов:** Линейная регрессия показала крайне низкую эффективность (отрицательные значения R^2) для всех регрессионных задач, что однозначно подтверждает сложный, нелинейный характер зависимостей между молекулярными дескрипторами и биологической активностью.
- Эффективность классификации:** В задачах бинарной классификации модели показали высокую результативность, особенно при прогнозировании низкой цитотоксичности ($CC50 >$ медианы), где F1-мера достигла 0.802.
- Ограниченный эффект оптимизации:** Процедура оптимизации гиперпараметров с помощью RandomizedSearchCV не привела к значимому улучшению качества моделей. В большинстве случаев изменения метрик (R^2 и F1) находились в пределах статистического шума, а в некоторых задачах даже привели к ухудшению результатов, что указывает на достижение «плато» для текущего набора данных и архитектур моделей.
- Анализ важности признаков:** На основе анализа важности признаков и SHAP-значений были выявлены ключевые молекулярные дескрипторы, оказывающие наибольшее влияние на прогнозы. Показано, что для разных целевых переменных доминируют различные структурные характеристики, такие как : VSA_EState8, NHOHCount, BalabanJ, BCUT2D_MRLOW.

Модели классификации готовы к использованию для скрининга новых соединений. Однако, учитывая, что текущий потенциал улучшения за счет простого перебора гиперпараметров исчерпан, для дальнейшего повышения качества прогнозов рекомендуется сфокусироваться на следующих направлениях:

- Инженерия признаков, включая создание новых дескрипторов и более глубокий отбор существующих.
- Применение более сложных архитектур, таких как LightGBM, CatBoost, а также методов ансамблирования (Stacking, Voting).
- Использование методов регуляризации для борьбы с переобучением.
- В случае необходимости повышения точности для наиболее сложных задач (например, прогнозирование SI), рассмотреть возможность увеличения выборки или использования специализированных подходов к работе с несбалансированными данными.